

Optimización de Costos

Matriz comparativa de modelos IA y justificación de la elección por tarea

Alan Gutierrez — Coderhouse, IA Automation

Contexto

El sistema ejecuta una única tarea de IA por lead: clasificar un mensaje de texto corto (nombre, email, canal de origen y un mensaje de pocas líneas) en dos categorías, VIP o No VIP. Es una tarea de **clasificación simple de baja complejidad semántica**, no de razonamiento profundo ni de generación de contenido extenso. Elegir el modelo correcto para esta tarea puntual, en lugar de usar por defecto el modelo más potente disponible, es la decisión de optimización de costos central del proyecto.

Matriz comparativa de modelos (vía OpenRouter)

Modelo	Costo aprox. (input / output, por 1M tokens)	Latencia típica	Calidad para clasificación corta	Uso recomendado en este proyecto
GPT-4o-mini (elegido)	~US\$0.15 / US\$0.60	Baja (~1- 2s)	Alta — sobra para clasificar 2 categorías a partir de ~150 tokens de contexto	Clasificación del lead (tarea actual)
GPT-4o	~US\$2.50 / US\$10.00	Media	Alta (sobredimensionado)	Reservar para tareas que requieran razonamiento complejo multi-paso (no existen hoy en este flujo)
Claude Sonnet	~US\$3.00 / US\$15.00	Media	Muy alta en comprensión de texto extenso y matices	Útil si en el futuro se analizan mensajes largos, contratos o adjuntos con contexto denso
Claude Haiku	~US\$0.25 / US\$1.25	Baja	Alta	Alternativa directa a GPT-4o- mini si se quisiera diversificar proveedor
Batch API (OpenAI/Anthropic)	~50% de descuento sobre el precio sync	Alta (no en tiempo real, horas)	Igual al modelo base	No aplica hoy (el flujo es 1 lead → 1 clasificación en tiempo real), pero sería la elección correcta si en el futuro se reprocesan leads históricos en lote (ej. reclasificar 10.000 leads viejos de una sola vez)

(Precios de referencia de mercado, sujetos a cambios por el proveedor; el punto relevante para la decisión es la magnitud relativa entre modelos, no el valor exacto del día.)

Justificación de la elección: GPT-4o-mini

1. **La tarea no requiere razonamiento profundo.** Clasificar “VIP” vs “No VIP” a partir de 3-4 campos cortos es un problema de patrón, no de cadena de razonamiento. Un modelo “mini” clasifica esto con la misma precisión práctica que un modelo de última generación, por lo que pagar la diferencia de precio no compra mejor resultado.
2. **Volumen y frecuencia.** Cada ejecución consume ~160 tokens totales (medido en ejecución real: promptTokens: 159, completionTokens: 2). Con GPT-4o-mini el costo por lead clasificado es de fracciones de centavo; con GPT-4o el mismo lead costaría **~17 veces más** por la sola diferencia de tarifa, sin ninguna mejora medible en la clasificación.
3. **Max Tokens limitado explícitamente.** El nodo de IA restringe la salida esperada a una palabra (VIP/No VIP), lo que además de ser un control de costos es un control de **seguridad del formato de salida**: evita que el modelo devuelva texto libre que rompa el router If posterior.
4. **Latencia.** Al ser un flujo con un humano esperando la notificación de Slack en el otro extremo (HITL), la menor latencia de un modelo “mini” reduce el tiempo total entre que el lead llega y el ejecutivo recibe el aviso.

Cuándo se justificaría cambiar de modelo

- Si se agregara un nodo que **resuma o analice el mensaje completo del lead en profundidad** (por ejemplo, extraer automáticamente los “Criterios VIP” en lenguaje natural, hoy dejado como campo manual/reservado), un modelo tipo Claude Sonnet sería la elección correcta por su mejor comprensión de matices y contexto extenso.
- Si el volumen de leads creciera a **procesamiento masivo por lotes** (ej. reclasificar toda la base histórica una vez por mes), la **Batch API** sería la opción correcta: mismo modelo, ~50% menos costo, a cambio de aceptar una respuesta no inmediata (aceptable porque un reproceso masivo no tiene un humano esperando en Slack).

Estimación de ahorro

Suponiendo un volumen de 1.000 leads/mes:

Escenario	Modelo	Costo estimado/mes (clasificación únicamente)
Elegido	GPT-4o-	≈ US\$0.09 (160 tokens promedio × 1.000 leads, tarifa mini)

Escenario	Modelo	Costo estimado/mes (clasificación únicamente)
	mini	
Alternativa sobredimensionada	GPT-4o	≈ US\$1.55 (misma carga, tarifa full)
Ahorro	—	≈ 94% de reducción en el costo de IA , sin pérdida de calidad de clasificación para esta tarea específica

La conclusión no es “limitar tokens” de forma genérica, sino **elegir el modelo cuya capacidad coincide con la complejidad real de la tarea**, y reservar modelos más caros (o el modo Batch) para las tareas que efectivamente los necesiten en el futuro del proyecto.